

คำตอบคำถามวิเคราะห์ (อ้างอิงตัวเลขจากการรันจริง)

1. หลังรวมไฟล์ orders: 752 แถว | หลังลบ duplicate (exact + order_id): 750 แถว

2. customer_id ไม่พบใน Master Data: 22 แถว

product_id ไม่พบใน Master Data: 2 แถว

3. ยอดขายที่ใช้ได้จริง (valid values + matched + PAID): 660 ธุรกิจ

ยอดขายสุทธิรวม: 10,224,044.08 บาท

4. จังหวัดที่มียอดขายสุทธิสูงสุด: กรุงเทพมหานคร

(2,612,955.87 บาท, 154 ธุรกิจ)

5. หมวดสินค้าที่มียอดขายสุทธิสูงสุด: Smartphone

(3,092,117.34 บาท, 178 ธุรกิจ)

6. หากสลับลำดับ merge ก่อน cleaning:

- ข้อมูลดิบยังมี exact-duplicate rows, order_id ซ้ำ, email/province ไม่มาตรฐาน,

และ dtype ยังไม่ถูกต้อง (discount เป็น string "%" ในไฟล์ ก.พ., วันที่ยังไม่ parse)

- merge บน key ที่ยังไม่ trim/clean (เช่น customer_id/product_id มีช่องว่างปน หรือ

discount เป็น string) จะทำให้ validate='m:1'/'1:1' อาจ error หรือ silently

สร้างแถวซ้ำ (fan-out) เพราะแถวซ้ำในต้นทางยังไม่ถูกลบ

- ผลคือ net_sales จะถูกคำนวณผิด (นับแถวซ้ำซ้อน) และ unmatched count จะสูงเกินจริง

เพราะ key ไม่ตรงกันจากปัญหา formatting ที่ยังไม่ได้ standardize

- สรุป: ความเชื่อมั่นของข้อมูล (data trust) ลดลงอย่างมีนัยสำคัญ ควร clean ก่อน merge เสมอ